

İSTANBUL TEKNİK ÜNİVERSİTESİ
LİSANSÜSTÜ EĞİTİM ENSTİTÜSÜ

TEZ İLERLEME RAPORU

Muhammet Cafer Ülker

501222503

İnşaat Mühendisliği

Hidrolik ve Su Kaynakları Mühendisliği

Rapor Sayısı: 1

Rapor Dönemi: 1



2025 Ocak/Haziran

**TEZ KONUSU: Makine Öğrenmesi ile Katmanlı ve Fiziksel Anlamlı Yağış-Akış
Modelleme Yaklaşımı: Konya Kapalı Havzası Çalışması**

TEZ İZLEME KOMİTESİ ÜYELERİ:

**Tez Danışmanı : Prof. Dr. Mehmet Cüneyd Demirel
İstanbul Teknik Üniversitesi**

**Eş Danışman (varsa): Dr. Öğr. Üyesi Cihangir Köyceğiz
Konya Teknik Üniversitesi**

**Üye : Dr. Öğr.Üyesi Erdal Kesgin
İstanbul Teknik Üniversitesi**

**Üye : Prof. Dr. Meral Büyükyıldız
Konya Teknik Üniversitesi**

İÇİNDEKİLER

| | <u>Sayfa</u> |
|--|--------------|
| DIŞ KAPAK | |
| İÇ KAPAK | |
| İÇİNDEKİLER | |
| 1. GİRİŞ, | 1 |
| 2. TEZ ÖNERİSİNDE SUNULAN ZAMAN PLANI..... | 2 |
| 3. SON ALTI AYLIK DÖNEME AİT ÇALIŞMANIN TEZ BÜTÜNLÜĞÜNDEKİ YERİ..... | 3 |
| 4. SON ALTI AYLIK DÖNEMDE ZAMAN PLANI İLE UYUMLU OLARAK GERÇEKLEŞTİRİLEN ÇALIŞMAR VE SONUÇLARIN AÇIKLANMASI..... | 4 |
| 5. SON ALTI AYLIK DÖNEMDE ZAMAN PLANINDA YER ALIP GERÇEKLEŞTİRİLEMİYEN ÇALIŞMALAR VE NEDENLERİ..... | 11 |
| 6. YÖNTEM DEĞİŞİKLİĞİ VE NEDENLERİ..... | 11 |
| 7. BİR SONRAKİ ALTI AYLIK DÖNEMDE YAPILACAK ÇALIŞMALAR VE AÇIKLANMASI..... | 12 |

1. GİRİŞ

Günümüzde artan nüfus, iklim değişikliği ve çevresel baskılar, su kaynaklarının sürdürülebilir yönetimini daha da karmaşık bir hale getirmiştir. Özellikle tarımsal ve endüstriyel faaliyetlerin yoğun olduğu bölgelerde su talebi giderek artarken, kaynakların taşıma kapasitesi bu talebi karşılamakta yetersiz kalabilmektedir. Bu nedenle, hidrolojik süreçlerin daha doğru ve kapsamlı şekilde modellenmesi, etkin su yönetim stratejilerinin geliştirilmesi açısından kritik öneme sahiptir. Türkiye'nin yarı kurak bölgelerinden biri olan Konya Kapalı Havzası (KKH), bu bağlamda özgün sorunlara sahip olup, modelleme çalışmaları için önemli bir örnek teşkil etmektedir.

Bu tez çalışmasının temel amacı, fiziksel süreçleri dikkate alan ve makine öğrenmesi algoritmalarıyla desteklenen modüler bir hidrolojik model geliştirmektir. Çalışma, yağış-akış ilişkisini ve buna bağlı diğer hidrolojik süreçleri hem zamansal hem de mekansal düzlemde analiz edebilecek bir yapı oluşturmaya yöneliktir. Modelin tasarımında, hidrolojik süreçleri temsil eden çok sayıda alt bileşenin ayrı alt modeller şeklinde ele alınması; bu alt modellerin birbiriyle iletişim içinde çalışarak bütünsel çıktılar üretmesi hedeflenmektedir.

Son altı aylık süreçte, bu hedef doğrultusunda çeşitli hazırlık çalışmaları gerçekleştirilmiştir. İlk olarak, modelin ilk testleri için Konya Kapalı Havzası'nda yer alan Halkapınar Alt Havzası (16141) çalışma alanı olarak seçilmiştir. Bu bölge, küçük yüzey alanı ve veri erişilebilirliği açısından avantaj sağlaması nedeniyle tercih edilmiştir. ERA5 reanaliz verileri (Hersbach et al., 2020) kullanılarak 1980–2020 yıllarını kapsayan meteorolojik veri seti oluşturulmuş ve bu veriler kullanılarak küçük ölçekli makine öğrenmesi modelleri test edilmiştir. Bu ilk modellerin amacı, sistemin temel veri işleme kapasitesini sınamak ve Python–PyTorch tabanlı geliştirme ortamının bütünlüğünü kontrol etmek olmuştur.

Bu dönemde ayrıca modelin teorik altyapısı ve mimarisi üzerinde yoğunlaşmış, ilk başta monolitik bir yapıya sahip olan ve farklı hidrolojik fonksiyonları aynı model sınıfı içerisinde alt fonksiyonlar olarak barındıran tasarımın yerine, daha modüler ve esnek bir yapıya geçilmiştir. Yeni yaklaşımda uzamsal örüntüler için Convolutional Neural Network (CNN), zamansal bağıntılar için ise Transformer mimarileri kullanılarak her bileşenin kendi yapay öğrenme modülü içerisinde temsil edilmesi sağlanmıştır. Böylece hem daha güçlü temsiller elde edilmiş hem de fiziksel süreçlerin ayrıştırılarak ayrı ayrı test edilebilir hale gelmesi sağlanmıştır.

Geliştirilen model, ilerleyen dönemlerde Konya Kapalı Havzası'nın tamamına uygulanabilecek şekilde ölçeklenebilir bir yapıya sahiptir. Bu süreçte yüksek hesaplama gücü gereksinimi doğacağından, modelin eğitimi ve optimizasyonu için İstanbul Teknik Üniversitesi'nin Ulusal Yüksek Başarımlı Hesaplama Merkezi (UHEM) altyapısının kullanılması planlanmaktadır. Araştırmacı, geçmişte bu merkezde hidrolojik modelleme ve optimizasyon deneyimi kazanmış olup, mevcut çalışmanın da bu hizmet ve bireysel deneyimden faydalanacağı düşünülmektedir.

Bu ilerleme raporu, yukarıda özetlenen kapsamda yürütülen çalışmaları, karşılaşılan zorlukları ve önümüzdeki döneme yönelik planlamaları içermekte; tez önerisinde sunulan iş-zaman çizelgesiyle uyumlu olarak projenin gelişim sürecini belgelemektedir.

2. TEZ ÖNERİSİNDE SUNULAN ZAMAN PLANI

Çalışmayla ilgili tez önerisinde sunulan zaman planında, çalışmanın sekiz temel adımdan oluşan bir süreçte tamamlanması öngörülmüştür (Şekil 1). Bu temel adımlar, çalışmanın kavramsal çerçevesinden modelleme ve değerlendirme süreçlerine kadar tüm bileşenleri kapsamaktadır. İlk altı aylık döneme karşılık gelen kısım ise, bu sekiz adımdan ilk dört tanesini içermektedir. Bu dört adım aşağıda özetlenmiştir:

- **Genel Bakış ve Veri Temini:** Bu adım, çalışmanın başlangıç noktasının tanımlanması, araştırma ve planlama sürecinin yapılandırılması ve teknik çalışma ortamının oluşturulması gibi temel hazırlık faaliyetlerini kapsamaktadır.
- **Literatür Taraması:** Tezin temel taşlarından biri olan bu bölümde, literatürde yer alan ilgili çalışmaların sistematik olarak incelenmesi ve çalışmaya katkı sağlayacağı öngörülen yaklaşımların analiz edilmesi hedeflenmektedir. Ayrıca bu süreç, güncel gelişmeleri takip etmek ve karşılaşılan problemlere yönelik önceki çalışmaların çözümlerini değerlendirmek amacıyla tez yazım sürecine kadar sürdürülecektir.
- **Veri İşleme ve Küçük Ölçekli Makine Öğrenmesi Modeli Oluşturma:** Bu aşamada ham verilerin temizlenmesi, dönüştürülmesi ve modele uygun forma getirilmesi sağlanmıştır. Bunun yanı sıra, ilk aşamada küçük ölçekli bir makine öğrenmesi modelinin oluşturulması ve hiperparametre optimizasyonu ile katman yapılarının deneysel olarak tasarlanması gerçekleştirilmiştir.
- **Kod Refaktoringi ve Makine Öğrenmesi Modelinin Ölçeklendirilmesi:** Bu adımda, mevcut kod altyapısının yeniden düzenlenmesi, modüler yapıların eklenmesi ve yazılımın genel verimliliğinin artırılması hedeflenmiştir. Aynı zamanda küçük ölçekli modelden daha büyük ve karmaşık bir yapıya geçişe yönelik ön hazırlıklar da bu süreçte başlatılmıştır.

İŞ-ZAMAN ÇİZELGESİ

| İş Paketi Ad/Tanım | AYLAR | | | | | | | | | | | | | | | | | | | | | | | |
|--|-------|---|---|---|---|---|---|---|---|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|
| | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 | 16 | 17 | 18 | 19 | 20 | 21 | 22 | 23 | 24 |
| 1) Genel Bakış ve Veri Temini | x | x | x | x | x | x | | | | | | | | | | | | | | | | | | |
| 2) Literatür Taraması | | x | x | x | x | x | x | x | x | x | x | x | x | x | x | x | x | x | x | x | x | | | |
| 3) Veri İşleme ve Küçük Makine Öğrenmesi Modeli Oluşturma | | x | x | x | x | x | x | x | | | | | | | | | | | | | | | | |
| 4) Kod Refactoring ve Makine Öğrenmesi Model Ölçeklendirme | | | | | x | x | x | x | x | x | x | x | | | | | | | | | | | | |
| 5) Makine Öğrenmesi Modelinin Geliştirilmesi ve Son Haline Getirme | | | | | | | | x | x | x | x | x | | | | | | | | | | | | |
| 6) Kıyas Çalışması için Fiziksel Tabanlı Bir Modelin Konya Kapalı Havzasına Kurulması Amacıyla Girdi Veri Setinin Hazırlanması | | | | | | | | | | | | | x | x | x | | | | | | | | | |
| 7) Fiziksel Tabanlı Bir Modelin KKH için Kurulması ve Geliştirilen Makine Öğrenmesi Modeli ile Kıyas Çalışması | | | | | | | | | | | | | | | | x | x | x | x | x | x | | | |
| 8) Genel Değerlendirme ve Tez Yazım Süreci | | | | | | | | | | | | | | | | | | | | | | x | x | x |

Şekil 1. İş-Zaman Çizelgesi

3. SON ALTI AYLIK DÖNEME AİT ÇALIŞMANIN TEZ BÜTÜNLÜĞÜNDEKİ YERİ

Son altı aylık dönemde yürütülen çalışmalar, tez bütünlüğü açısından temel bir işlev üstlenmektedir. Bu dönemde, çalışmanın uygulanabilirliğini test etmek amacıyla Konya Kapalı Havzası içerisinde yer alan uygun bir alt havza seçilmiştir. Bu seçim, modelin erken geliştirme ve test süreçleri için ideal bir başlangıç ortamı oluşturmuştur.

Çalışmada kullanılacak veri setleri belirlenmiş ve ihtiyaç duyulabilecek ek veri kaynakları analiz edilmiştir. Ayrıca, çalışmanın ilk fazı için uygun hesaplama ortamları değerlendirilmiş ve ilerleyen aşamalarda kullanılabilecek alternatif işlem altyapıları planlanmıştır. Literatür taraması, bu dönemde kesintisiz olarak sürdürülmüş; yeni geliştirilen yöntemler ve benzer çalışmalar güncel olarak takip edilmiştir. İleriki dönemlerde de sürdürülmesi planlanmaktadır.

Başlangıçta, temel düzeyde makine öğrenmesi modelleri test edilerek çalışmanın kavramsal altyapısı güçlendirilmiştir. Bu temel denemeler sonrasında, modüler, çok katmanlı ve daha karmaşık bir model yapısının teorik tasarımı gerçekleştirilmiş ve modelin ilk versiyonunun inşasına geçilmiştir. Tez önerisinde belirtilen fiziksel anlamlılık hedefi doğrultusunda, model bileşenlerinin hidrolojik süreçlerle ilişkilendirilmesi sağlanmış ve fiziksel kavramların model tasarımına entegre edilme süreci başlatılmıştır.

Bu dönem, tez önerisinde sunulan hipotezlerin test edilmesini mümkün kılacak olan makine öğrenmesi modelinin çekirdek mimarisinin oluşturulduğu kritik bir aşamayı temsil etmektedir. Süreç içerisinde basit yapılardan karmaşık yapılara doğru ilerleyen model tasarımı yaklaşımı

ele alınmıştır. Tezin bilimsel özgünlüğünü sağlayacak olan temel yapı bu aşamada oluşturulmuştur.

4. SON ALTI AYLIK DÖNEMDE ZAMAN PLANI İLE UYUMLU OLARAK GERÇEKLEŞTİRİLEN ÇALIŞMALAR VE SONUÇLARIN AÇIKLANMASI

Tez önerisinde belirtilen zaman planı doğrultusunda, son altı aylık dönemde aşağıdaki çalışmalar gerçekleştirilmiştir:

Öncelikle, Konya Kapalı Havzası içinde yer alan ve 16141 numaralı Akım Gözlem İstasyonu'nu barındıran Halkapınar Alt Havzası, çalışma alanı olarak belirlenmiştir. Bu alan, yüzey alanının görece küçük oluşu, yeterli miktarda veri içermesi ve literatürde daha önce çalışılmış olması (Köyceğiz, 2022) nedeniyle tercih edilmiştir. Böylelikle geliştirilecek modellerin kontrollü ve daha anlaşılır bir ölçekte sınanması mümkün olmuştur.

Halkapınar havzası için ERA5 reanaliz verileri kullanılarak 1980–2020 yılları arasını kapsayan meteorolojik veri seti oluşturulmuştur. Bu veriler, ilk aşamada küçük ölçekli makine öğrenmesi modellerinin denenmesi için kullanılmıştır. Bu modellerde asıl amaç, kullanılan dijital altyapının makine öğrenmesi tabanlı model üretimine uygunluğunu test etmek olmuştur. Böylece, veri akışı, kod bütünlüğü ve modelleme ortamı sınanmış; sistemin işlemeye elverişli olup olmadığı ortaya konmuştur (Şekil 2).

```

1 import torch
2 import torch.nn as nn
3
4 class ComplexSpatioTemporalModel(nn.Module):
5     def __init__(self, nan_mask):
6         super(ComplexSpatioTemporalModel, self).__init__()
7
8         # NaN maskesi - non-NaN değerlerin yerini belirlemek için
9         self.nan_mask = nan_mask.float()
10
11         # İlk Convolutional katmanlar
12         self.conv1 = nn.Conv2d(in_channels=1, out_channels=32, kernel_size=(3, 1), padding=(1, 0)) # width=3
13         self.conv2 = nn.Conv2d(in_channels=32, out_channels=64, kernel_size=(3, 1), padding=(1, 0))
14
15         # Zaman serisi için LSTM katmanı
16         self.lstm = nn.LSTM(input_size=64 * 3, hidden_size=128, num_layers=2, batch_first=True)
17
18         # Fully connected katmanlar
19         self.fc1 = nn.Linear(128, 256)
20         self.fc2 = nn.Linear(256, 192) # 192, [8, 24] çıkışıyla uyumlu hale gelmesi için
21
22     def forward(self, x):
23         batch_size = x.size(0)
24
25         # Kanal boyutunu eklemek için unsqueeze işlemi yapma
26         x = x.unsqueeze(1) # [batch, channels=1, height, width=3]
27
28         # Convolutional katmanlar
29         x = torch.relu(self.conv1(x))
30         x = torch.relu(self.conv2(x))
31
32         # 2D veriyi LSTM için uygun boyuta getirme
33         x = x.view(batch_size, -1, 64 * 3) # [batch, time_steps, features]
34         x, _ = self.lstm(x)
35
36         # Son LSTM çıktısını fully connected katmanlara gönderme
37         x = torch.relu(self.fc1(x[:, -1, :])) # Sadece son zaman adımını al
38         x = self.fc2(x)
39
40         # Çıkışı [8, 24] boyutuna getirme
41         x = x.view(-1, 8, 24)
42
43         # NaN maskesini son çıktıda uygulayarak NaN değerleri koruma
44         x = x * self.nan_mask + (1 - self.nan_mask) * torch.tensor(float('-999'), device=x.device)
45
46         return x
47

```

Şekil 2. Küçük ölçekli makine öğrenmesi ilk denemelerden kod örneği

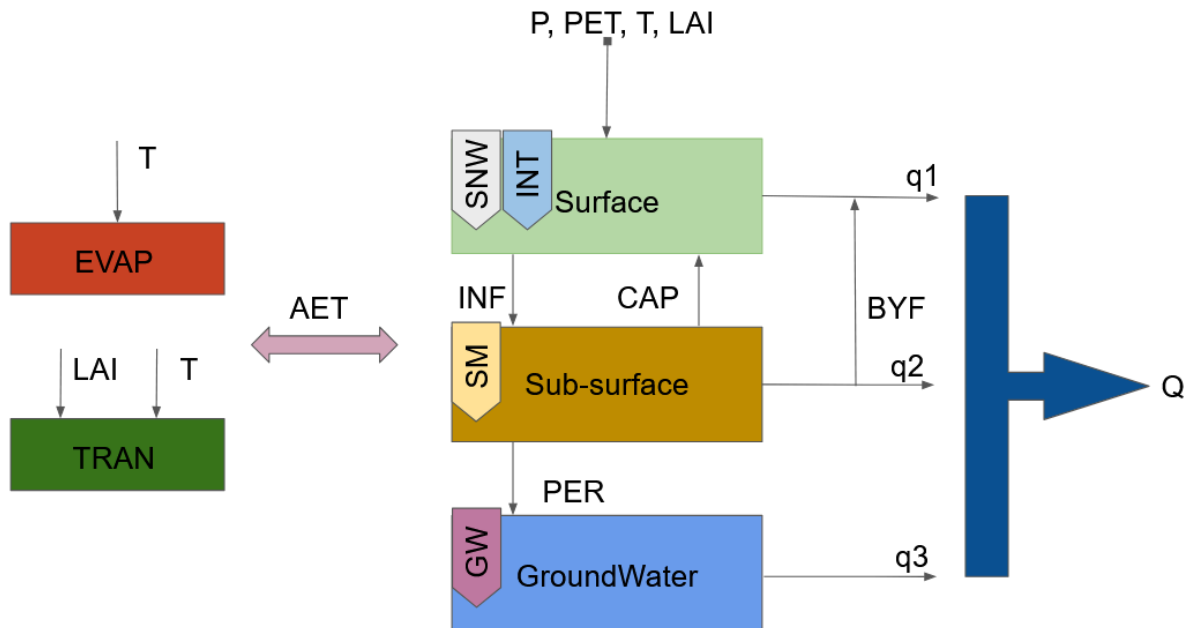
Ayrıca, çalışmanın ilerleyen aşamalarında kullanılmak üzere Transfer Learning yöntemlerinin potansiyelinden faydalanmak amacıyla bazı ön denemeler gerçekleştirilmiştir. Bu denemeler, farklı alanlarda önceden eğitilmiş modellerin, çalışmanın özel bağlamına adapte edilmesi sürecine hazırlık niteliğindedir. Ancak bu modeller, yüksek doğruluk hedefiyle optimize edilmemiştir. Bunun temel nedeni, kullanılan model yapılarına verilen düşük çözünürlüklü ve sınırlı sayıda girdi (örneğin yalnızca yağış ve sıcaklık verileri, çözünürlük 1x3) ile anlamlı çıktılar üretmenin beklenmemesidir. Bu tür bir durumda başarılı sonuçlar elde edebilmek, yüksek hesaplama gücü ve uzun süreli eğitim gerektirir ki bu da zaman ve donanım açısından ciddi maliyetleri beraberinde getirecektir. Bu nedenle söz konusu prototip modellerin çıktıları

yalnızca sistem geçerliliği ve Transfer Learning metodunun yapılabilirliğinin kanıtı niteliğinde değerlendirilmiş ve daha sonraki aşamalara geçilmiştir.

Bu dönemde ayrıca, geliştirilecek makine öğrenmesi modelinin teorik çerçevesi ve mimarisi üzerine detaylı çalışmalar yürütülmüştür. İlk olarak, modelin temel alacağı hidrolojik sistemin kavramsal temsili oluşturulmuştur. Bu kapsamda, fiziksel temsiliyeti olan üç hazneli bir hidrolojik akış şeması temel alınarak, sürecin hidrolik bileşenleri tanımlanmıştır. Ardından, bu yapının makine öğrenmesi modelleriyle nasıl temsil edilebileceği değerlendirilmiş; özellikle makine öğrenmesinin sistemin hangi bileşenlerinde görev alacağı ve hangi tür çıktıların üretileceği planlanmıştır. Bu süreçte, veri akışı, bilgi dönüşümü ve fiziksel anlamlılık bağlamında yapay öğrenme modüllerinin hangi aşamalarda devreye gireceği detaylı şekilde tasarlanmıştır. Son olarak, belirlenen mimariye uygun şekilde modelin yapısal kodlamasına başlanmış ve ilk versiyonun uygulanmasına geçilmiştir (Şekil 3). Mevcut haliyle model; yağış (P), potansiyel evapotranspirasyon (PET), sıcaklık (T) ve yaprak alanı indeksi (LAI) verilerini NetCDF (.nc) dosyası olarak kabul ediyor ve sonuç olarak temelde gerçek evapotranspirasyon (AET) ve akış (Q) haritaları üretiyor. Bunları yaparken Denklem 1 ile verilen su bütçesine tabi kalıyor.

$$P - ET = Q \quad (1)$$

Modelin esneklik kazanması, farklı senaryolara uyarlanabilmesi ve gelecekteki kapsam genişletmelerine olanak sağlaması amacıyla, mimari yapı modüler olarak tasarlanmıştır. Bu kapsamda, üç hazneli hidrolojik yapının her bir bileşeni bağımsız birer alt model şeklinde yapılandırılmıştır. Her bir alt model, temsil ettiği hidrolojik süreci simüle edecek şekilde kurgulanmış; bu modeller, ya doğrudan meteorolojik girdilerle ya da birbirlerinden gelen ara çıktılarla beslenecek şekilde birbirine bağlı hale getirilmiştir.



Şekil 3. ML modelinin hidrolojik akış şeması

Bu yapı sayesinde, sadece nihai çıktılar (akış ve evapotranspirasyon haritaları) değil, aynı zamanda her bir ara sürecin çıktısı da kullanıcı tarafından erişilebilir olacaktır. Böylelikle model, yalnızca sonuca odaklanmakla kalmayıp, süreç temelli analizlere olanak tanıyan bir araç olacak şekilde konumlanmıştır. Bu yönüyle, geliştirilen sistem kullanıcıya hidrolojik sürecin ara basamaklarına dair doğrudan gözlem ve analiz yapabilme imkânı sağlaması planlanmaktadır.

Bununla birlikte, modelin fiziksel anlamlılığını koruyabilmesi amacıyla, her bir alt model belirli hidrolojik koşulları ve fiziksel süreçleri temsil edecek şekilde tasarlanmış; bu süreçlerin tutarlı çalışabilmesi için çeşitli fiziksel kısıtlamalar ve denge koşulları modele entegre edilmesi planlanmıştır. Böylece modelin fiziksel sistem davranışını yansıtan yapısı da sürdürülmektedir.

Başlangıç aşamasında, model mimarisini tek bir monolit yapı altında kurgulamak amacıyla CNN, RNN ve Transformer gibi yaygın derin öğrenme mimarilerinin tek bir çatı altında entegre edildiği deneysel bir yapı denenmiştir. Bu yapı, giriş parametrelerinin bir “kara kutu” üzerinden öğrenilmesini sağlayacak şekilde tasarlanmış; böylelikle karmaşık hidrolojik ilişkilerin doğrudan model tarafından yakalanması hedeflenmiştir. Ancak bu yaklaşım, model parametrelerinin kontrolsüz biçimde çeşitlenmesiyle birlikte hem anlamlandırılması güç hataların oluşmasına hem de kullanılan kütüphaneler açısından teknik uyumsuzluklara neden olmuştur.

Bu deneyimin ardından, daha anlaşılabilir, modüler ve hidrolojik gerçeklik ile daha uyumlu bir yapı tasarlanmasına karar verilmiştir. Bu doğrultuda, mekansal ve zamansal bileşenlerin ayrı modeller tarafından işlenmesi esasına dayanan yeni bir mimari benimsenmiştir. Bu yapıya göre; mekansal örüntüler, özellikle topografik ve meteorolojik harita verilerinde yaygın olan yerel ilişkileri öğrenme yeteneği nedeniyle Convolutional Neural Network (CNN) yapıları ile modellenmektedir. CNN’ler, komşu pikseller arasındaki mekansal korelasyonları filtreler aracılığıyla öğrenme becerisi sayesinde, yüzey şekli, toprak tipi ve yağış dağılımı gibi coğrafi örüntülerin yakalanmasında etkili olmaktadır (LeCun et al., 1998).

Öte yandan, zamansal dinamiklerin modellenmesinde, uzun dönemli bağımlılıkları yakalama konusundaki üstünlükleri nedeniyle Transformer tabanlı yapılar tercih edilmiştir. Transformer mimarileri, self-attention mekanizması sayesinde tüm zaman adımları arasındaki ilişkileri aynı anda işleyebilmekte, bu sayede zaman serisi verilerde uzun vadeli bağıntılar kurulmasını sağlamaktadır (Vaswani et al., 2017). Ayrıca, sıralı işlem zorunluluğu olmadan paralel hesaplama yapabilmeleri, eğitim süresini kısaltmakta ve farklı zaman çözünürlüğüne sahip verilerin (günlük yağış, 8-günlük ET gibi) bütünleştirilmesine olanak sağlamaktadır (Dosovitskiy et al., 2021).

Bu mimari değişiklik sayesinde, model daha açık, modifiye edilebilir ve fiziksel süreçlerle daha doğrudan uyumlu hale gelmiştir. Aynı zamanda, ileride genişletilebilirlik ve yeniden kullanılabilirlik açısından daha sürdürülebilir bir yapı oluşturulmuştur.

Son aşamada üzerinde çalışılmakta olan modelin mimarisi, çok aşamalı ve modüler bir yapı temelinde kurgulanmıştır. Geliştirilen mimari, farklı çözünürlüklere ve zaman ölçeklerine sahip çok kaynaklı hidrolojik verilerin entegre edilmesini mümkün kılarken, modelin dinamik olarak büyütülebilmesine olanak sağlayacak şekilde esnek bir çerçeve sunmaktadır. Bu yaklaşım, benzer şekilde spatiotemporal bilgi çıkarımı ve otoregresif tahmin yetenekleri ile öne çıkan, sel haritalarının anlık tahmini için geliştirilen Transformer tabanlı FloodSformer modelinde de benimsenmiştir (Pianforini et al., 2024). Bu yapının genel bileşenleri aşağıdaki gibi özetlenebilir:

a) Uzamsal Entegrasyon (Spatial Integration)

- **Çözünürlükleri Eşitleme (Resampling):** Farklı mekansal çözünürlükteki veri katmanlarının uyumlu hale getirilmesi için interpolasyon ve yeniden örnekleme tekniklerinin uygulanması.
- **Çok-Dalga Boyu Özellik Çıkarımı (Multi-Scale CNN):** Farklı ölçeklerde yerel örüntüleri yakalamak amacıyla çok ölçekli evrişimsel katmanların kullanılması; bu katmanlar sayesinde toprak nemi, yağış deseni gibi fiziksel değişkenlerin mekansal bağlamı modele entegrasyonu.

b) Zamansal Entegrasyon (Temporal Alignment)

- **Ortak Zaman Çizelgesi (Shared Time Grid):** Günlük, 8-günlük ve aylık gibi farklı zaman çözünürlüklerine sahip veriler tek bir zaman eksenine indirgenerek modelin birlikte işlem yapabilmesi.
- **Asenkron Sıkıştırma (Event Tokenization):** Olay temelli (event-driven) veri parçalama teknikleri ile zamansal örüntüler daha anlamlı hale getirilmesi.
- **Hiyerarşik Zaman Modelleme (Hierarchical Transformer):** Zaman serilerinde kısa ve uzun dönemli bağıntıların birlikte modellenenebilmesi amacıyla çok seviyeli Transformer yapılarının kullanılması..

c) Modül Füzyonu (Modality Fusion)

- **Modality-Type Embedding:** Farklı veri türlerinin (örneğin, LAI ve yağış) temsil edildiği modalitelerin ayrı ayrı kodlanarak modele aktarılması.
- **Cross-Attention Katmanları:** Modaliteler arası bilgi alışverişi, karşılıklı dikkat (cross-attention) mekanizmaları ile sağlanması.
- **Auto-Regressive Döngü:** Model çıktılarının yeniden giriş olarak kullanıldığı geri beslemeli yapı, sistemin çok adımlı tahmin yeteneğini geliştirir.

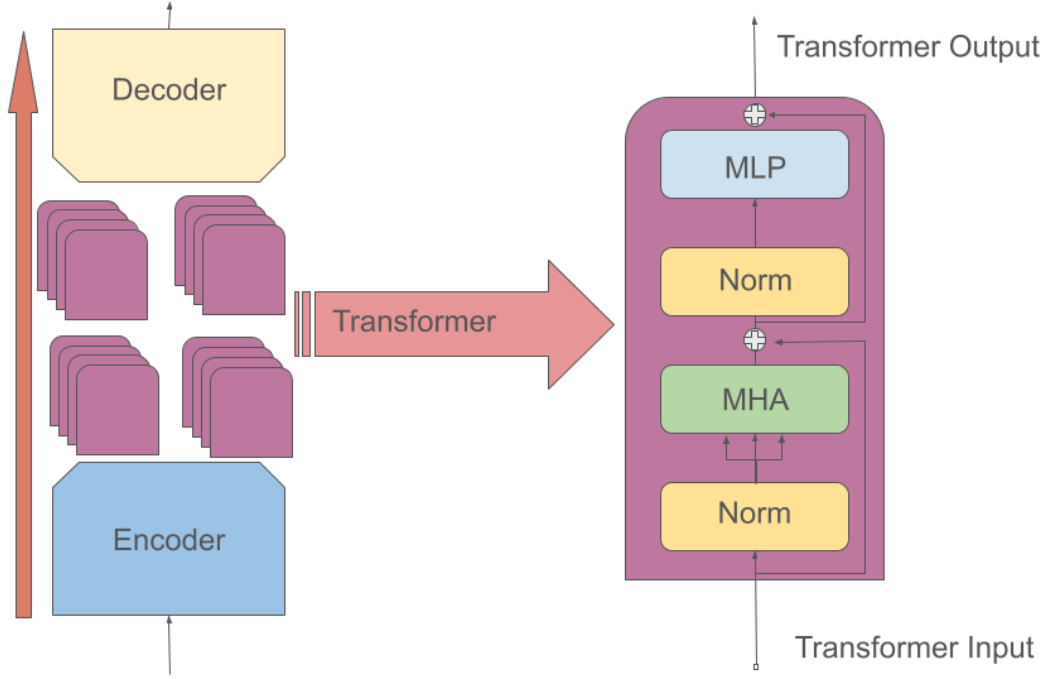
d) Çıktı Katmanı & Otoregresyon

- **Dekoder Modülü:** Öğrenilen temsil üzerinden gelecek adım haritalarının (örneğin, günlük runoff veya evapotranspirasyon) üretilmesini sağlamaktadır.
- **Yinelenen Döngü:** Üretilen yeni veriler, bir sonraki adımda yeniden modelin girdisi haline getirilerek ardışık tahmin yeteneği artırılmıştır. Bu daima kendini güncelleyen bir model oluşturmamızı sağlamaktadır.


Bu yapı, çok aşamalı modüler akış ile Şekil 4’te şematik olarak gösterilmiştir. Bu mimari sayesinde her bir alt model birbirine bağlı ancak bağımsız çalışabilir hale gelmiş ve aşağıdaki avantajlar sağlanmıştır:

- **Modüler Geliştirme:** Örneğin, toprak nemi alt modelinin iç yapısı değiştirildiğinde diğer alt modeller bundan etkilenmemektedir. Çünkü diğer alt modeller sadece toprak nemi modelinin çıktıları ile etkileşime girmektedir.
- **Kolay Ölçeklendirme:** Model çıktılarını çeşitlendirmek ya da detaylandırmak için yeni bir alt modülün eklenmesi yeterli olmaktadır.
- **Dinamik Grafik:** Model, çalıştırma sırasında hangi modülün ne zaman tetikleneceğini dinamik olarak belirleyebilmekte ve işlem sırasını veriye göre uyarlayabilmektedir.

a)



b)



Şekil 4. Üzerinde çalışılan modele ait iki ayrı akış şeması. a) Ortak Encoder/Decoder b) Parçalı Encoder/Decoder

Üzerinde çalışılan bu model aynı zamanda, ilerleyen dönemlerde çalışmanın daha büyük bir coğrafi ölçekte —örneğin Konya Kapalı Havzası’nın tamamı veya bir kısmı üzerinde— uygulanmasına yönelik olarak tasarlanacak olan genişletilmiş model mimarisi için de bir ön hazırlık niteliği taşımaktadır. Bu bağlamda geliştirilen sistem, beşinci adımda tanımlanan “Büyük Ölçekli Modelleme” aşaması için kavramsal ve teknik altyapıyı oluşturmaktadır.

Tez öneri formunda yer alan İş-Zaman Çizelgesi kapsamında, bu dönemde “Veri İşleme ve Küçük Ölçekli Makine Öğrenmesi Modeli Oluşturma” başlığı altındaki çalışmaların büyük bir kısmı başarıyla tamamlanmıştır. Hâlihazırda “Kod Refaktoringi ve Makine Öğrenmesi Model Ölçeklendirme” aşaması üzerinde aktif olarak çalışılmaktadır. Ayrıca, nihai modelin geliştirilmesi ve son hâline kavuşturulmasına yönelik adımlara da bu dönem itibarıyla başlanmış durumdadır.

5. SON ALTI AYLIK DÖNEMDE ZAMAN PLANINDA YER ALIP GERÇEKLEŞTİRİLEMEYEN ÇALIŞMALAR VE NEDENLERİ

Son altı aylık dönem için zaman planında öngörülmüş olup da gerçekleştirilemeyen başlıca faaliyet, makine öğrenmesi modellerine yönelik ayrıntılı optimizasyon çalışmalarıdır. Bu çalışmaların, özellikle küçük ölçekli prototip modeller üzerinde uygulanmasının, hem zaman hem de donanım maliyeti açısından anlamlı bir katkı sağlamayacağı değerlendirilmiştir. Söz konusu küçük modeller, esasen dijital altyapının işleyişini test etmek ve veri akışını doğrulamak amacıyla kullanıldığından, planlı olarak görmezden gelinmiştir.

Bunun yanı sıra, şu anda geliştirilmekte olan ve tez çalışmasının çekirdek bileşenini oluşturacak olan ana modelin kalibrasyon ve optimizasyon süreçleri de henüz uygulanmamıştır. Bu durumun temel nedeni, söz konusu modelin yapısal olarak hâlâ geliştirilme aşamasında olmasıdır. Modelin nihai biçimini almasının ardından, detaylı performans analizleri ve kalibrasyon adımlarına geçilecektir.

Ancak burada dikkat edilmesi gereken bir husus da, tez öneri formunda sunulan İş-Zaman Çizelgesi'nde "Veri İşleme ve Küçük Ölçekli Makine Öğrenmesi Modeli Oluşturma" ile "Kod Refaktoringi ve Makine Öğrenmesi Model Ölçeklendirme" aşamalarının altı aylık süreden daha uzun bir zaman aralığına yayılacak şekilde planlanmış olmasıdır. Dolayısıyla, ilgili dönemde optimizasyon sürecinin henüz tamamlanmamış olması, zaman planına aykırı değil; bilakis, öngörülen ilerleme temposu ile uyumlu bir durumdur.

Ayrıca, bu dönemde detaylı optimizasyon sürecinin başlatılamamış olmasının bir diğer önemli nedeni de, bu sürecin oldukça yüksek donanımsal gereksinimler talep edebilecek olmasıdır. Optimizasyon ve hiperparametre arama işlemleri, uzun süreli hesaplamalar ve yüksek belleğe sahip GPU kaynakları gerektirdiğinden, mevcut altyapı koşullarıyla yürütülmesi mümkün olamayabilir. Bu nedenle, ilerleyen dönemlerde bu işlemlerin yürütülebileceği alternatif hesaplama platformlarının (UHeM) değerlendirilmesi ve entegrasyonu planlanmaktadır.

6. YÖNTEM DEĞİŞİKLİĞİ VE NEDENLERİ

Bu tez kapsamında, ilk altı aylık süreçte temel araştırma yaklaşımı ve modelleme stratejisinde köklü bir yöntem değişikliğine gidilmemiştir. Ancak, geliştirilen makine öğrenmesi mimarisinde yapılan veya yapılabilecek olası yapısal bir revizyon, sınırlı ölçüde bir yöntemsel değişiklik olarak değerlendirilebilir.

Çalışmanın ilk aşamalarında, tüm hidrolojik süreçleri tek bir yapay sinir ağı içerisinde barındıran, görece daha monolitik, dışarıdan bir algoritma ile kontrol edilen bir model tasarımı benimsenmişti. Bu tasarımda, farklı hidrolojik bileşenler model içerisinde ayrı alt fonksiyonlar olarak temsil edilmekteydi. Ancak bu yaklaşımın hem hata izleme ve bakım açısından zorluklar yaratması hem de hidrolojik süreçlerin ayrık olarak modellenmesini kısıtlaması nedeniyle, daha esnek ve katmanlı bir mimariye geçiş yapılmıştır.

Yeni yaklaşımda, uzamsal verilerin işlenmesi için CNN yapıları; zamansal dinamiklerin modellenmesi için ise Transformer tabanlı modüller kullanılarak, modüler ve iç içe geçmiş bir

sistem tasarımı benimsenmiştir. Bu değişiklik, önceki bölümlerde de detaylı biçimde açıklanan teknik ve kuramsal gerekçelere dayanmaktadır.

7. BİR SONRAKİ ALTI AYLIK DÖNEMDE YAPILACAK ÇALIŞMALARIN AÇIKLANMASI

Önümüzdeki altı aylık dönemde, tez çalışmasının en önemli ve belirleyici aşamalarından birine geçilmesi planlanmaktadır. Bu kapsamda, hâlihazırda geliştirilmekte olan detaylı ve kompleks makine öğrenmesi modelinin yapısal olarak tamamlanması, ardından modelin hiperparametre optimizasyonu ve kalibrasyon süreçlerinin gerçekleştirilmesi hedeflenmektedir.

Modelin yalnızca küçük ölçekli bir alt havzada (Halkapınar) değil, aynı zamanda Konya Kapalı Havzası'nın tamamı veya bir kısmı üzerinde de uygulanması planlanmaktadır. Böylece modelin genellenebilirliği, fiziksel geçerliliği ve farklı hidrolojik koşullarda gösterdiği performans kapsamlı bir şekilde değerlendirilecektir.

Ancak bu aşamaya geçilebilmesi için çözülmesi gereken temel bir gereklilik söz konusudur: yüksek düzeyde hesaplama kapasitesi. Bu sebeple, İstanbul Teknik Üniversitesi Ulusal Yüksek Başarımlı Hesaplama Merkezi'nin (UHeM) sunduğu altyapının bu süreçte kullanılması planlanmaktadır. UHeM sistemlerinin Linux tabanlı olması, Python programlama dilini desteklemesi ve PyTorch gibi derin öğrenme kütüphanelerinin kurulabilir olması, mevcut modelin bu platformda çalıştırılabilirliğini mümkün kılmaktadır.

Araştırmacının daha önce UHeM ortamında bir hidrolojik model (ve buna entegre edilmiş bir PEST optimizasyon algoritması) çalıştırmış olması, bu sürece ilişkin teknik bilgi birikimini ve uygulama deneyimini de beraberinde getirmektedir. Bu nedenle, modelin geniş ölçekli uygulama ve optimizasyon çalışmalarının UHeM altyapısı üzerinde gerçekleştirilmesi planlı ve uygulanabilir bir hedef olarak değerlendirilmektedir.

KAYNAKÇA

- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2020).** An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale. International Conference on Learning Representations (ICLR) 2021.
- Hersbach, H., Bell, B., Berrisford, P., et al. (2020).** The ERA5 global reanalysis. Quarterly Journal of the Royal Meteorological Society, 146, 1999–2049. <https://doi.org/10.1002/qj.3803>
- Köyceğiz, C. (2022).** Konya Kapalı Havzası’nda arazi örtüsü/arazi kullanım değişiminin etkileri ve su bütçesi bileşenleri ile ilişkisi: Tarihsel inceleme ve gelecek perspektifi (Doktora tezi). Konya Teknik Üniversitesi, Lisansüstü Eğitim Enstitüsü, Konya.
- LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998).** Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11), 2278–2324. <https://doi.org/10.1109/5.726791>
- Pianforini, M., Dazzi, S., Pilzer, A., & Vacondio, R. (2024).** Real-time flood maps forecasting for dam-break scenarios with a transformer-based deep learning model. Journal of Hydrology, 635, 131169. <https://doi.org/10.1016/j.jhydrol.2024.131169>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017).** Attention is All You Need. In I. Guyon, U. von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, & R. Garnett (Eds.), Advances in Neural Information Processing Systems, 30, 5998–6008.